

**AGL10225 – Aprendizado por Reforço**

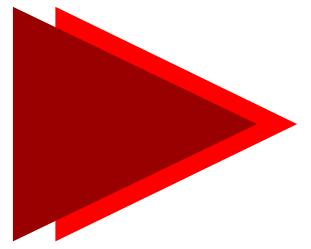


# Planejamento de rota de veículo articulado em ambiente de estacionamento

DAYANA CARDOSO

WALTER FRANK

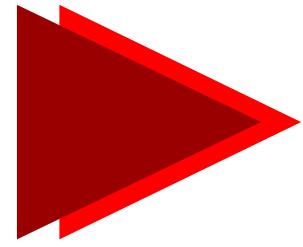
# Introdução



O planejamento de movimento para veículos articulados (ex: uniciclo com reboque) em ambientes não estruturados enfrenta o desafio da **complexidade cinemática local e topológica global**.

- Controladores baseados em otimização (MPC) resolvam a estabilização local, mas sofrem em navegação global com **obstáculos** (mínimos locais).
- Abordagens de Aprendizado por Reforço (RL) prometem robustez global, mas sofrem com o problema do **horizonte longo**

Nesse contexto, exploramos o potencial do Heuristic Guided Reinforcement Learning (HuRL) para **reduzir a esparsidade** da recompensa e aumentar a eficiência de treinamento de agente de RL.



# HuRL

Cheng et al, introduziram o **Heuristic-Guided Reinforcement Learning (HuRL)** como uma solução para acelerar o RL. O HuRL utiliza uma heurística (mesmo que imperfeita) para "encurtar" o horizonte efetivo do problema através da moldagem de recompensa (reward shaping) baseada em potencial. No entanto, a eficácia do HuRL depende criticamente da qualidade desta heurística inicial.

Nesse contexto, exploramos diferentes **heurísticas** para modelar a recompensa do agente, comparando seu impacto efetivo na eficiência e velocidade de treinamento.

# Metodologia

## Modelagem do Domínio Físico

Modelamos a entidade trator-trailer, seu ambiente físico, interações e dinâmicas em um ambiente da api Gymnasium customizado.

## Definição das Heurísticas para Reward Shaping

Instrumentamos o ambiente de aprendizado com duas heurísticas principais, que modelam a recompensa do agente a cada passo de forma distinta:

- **Distância euclidiana:** Recompensa o agente por reduzir a distância em linha reta até o objetivo
- **Distância de menor caminho considerando obstáculos (BFS):** Recompensa o agente por seguir o menor caminho válido até o objetivo, reduzindo a menor distância calculada pelo BFS.

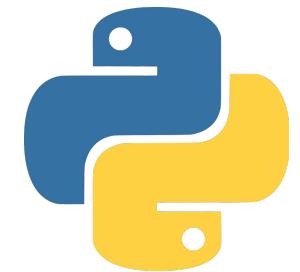
# Metodologia

## Treinamento e Comparação

- Treinamos agentes de aprendizado por reforço por um número fixo de passos com cada heurística, usando o mesmo algoritmo
- Comparamos o desempenho de treinamento dos agentes entre si e ao baseline – um agente treinado sem heurística.

# Modelagem do Domínio

# Pilha de Software



## Python

Linguagem de programação principal



## Tensorboard

Acompanhamento em tempo real de treinamentos



## OpenAI Gymnasium

API para ambiente de aprendizado por reforço



## CasADI

Otimização numérica, diferenciação algoritmica



## Stable-baselines3

Implementações de algoritmos de RL compatíveis com Gymnasium

## Outras bibliotecas

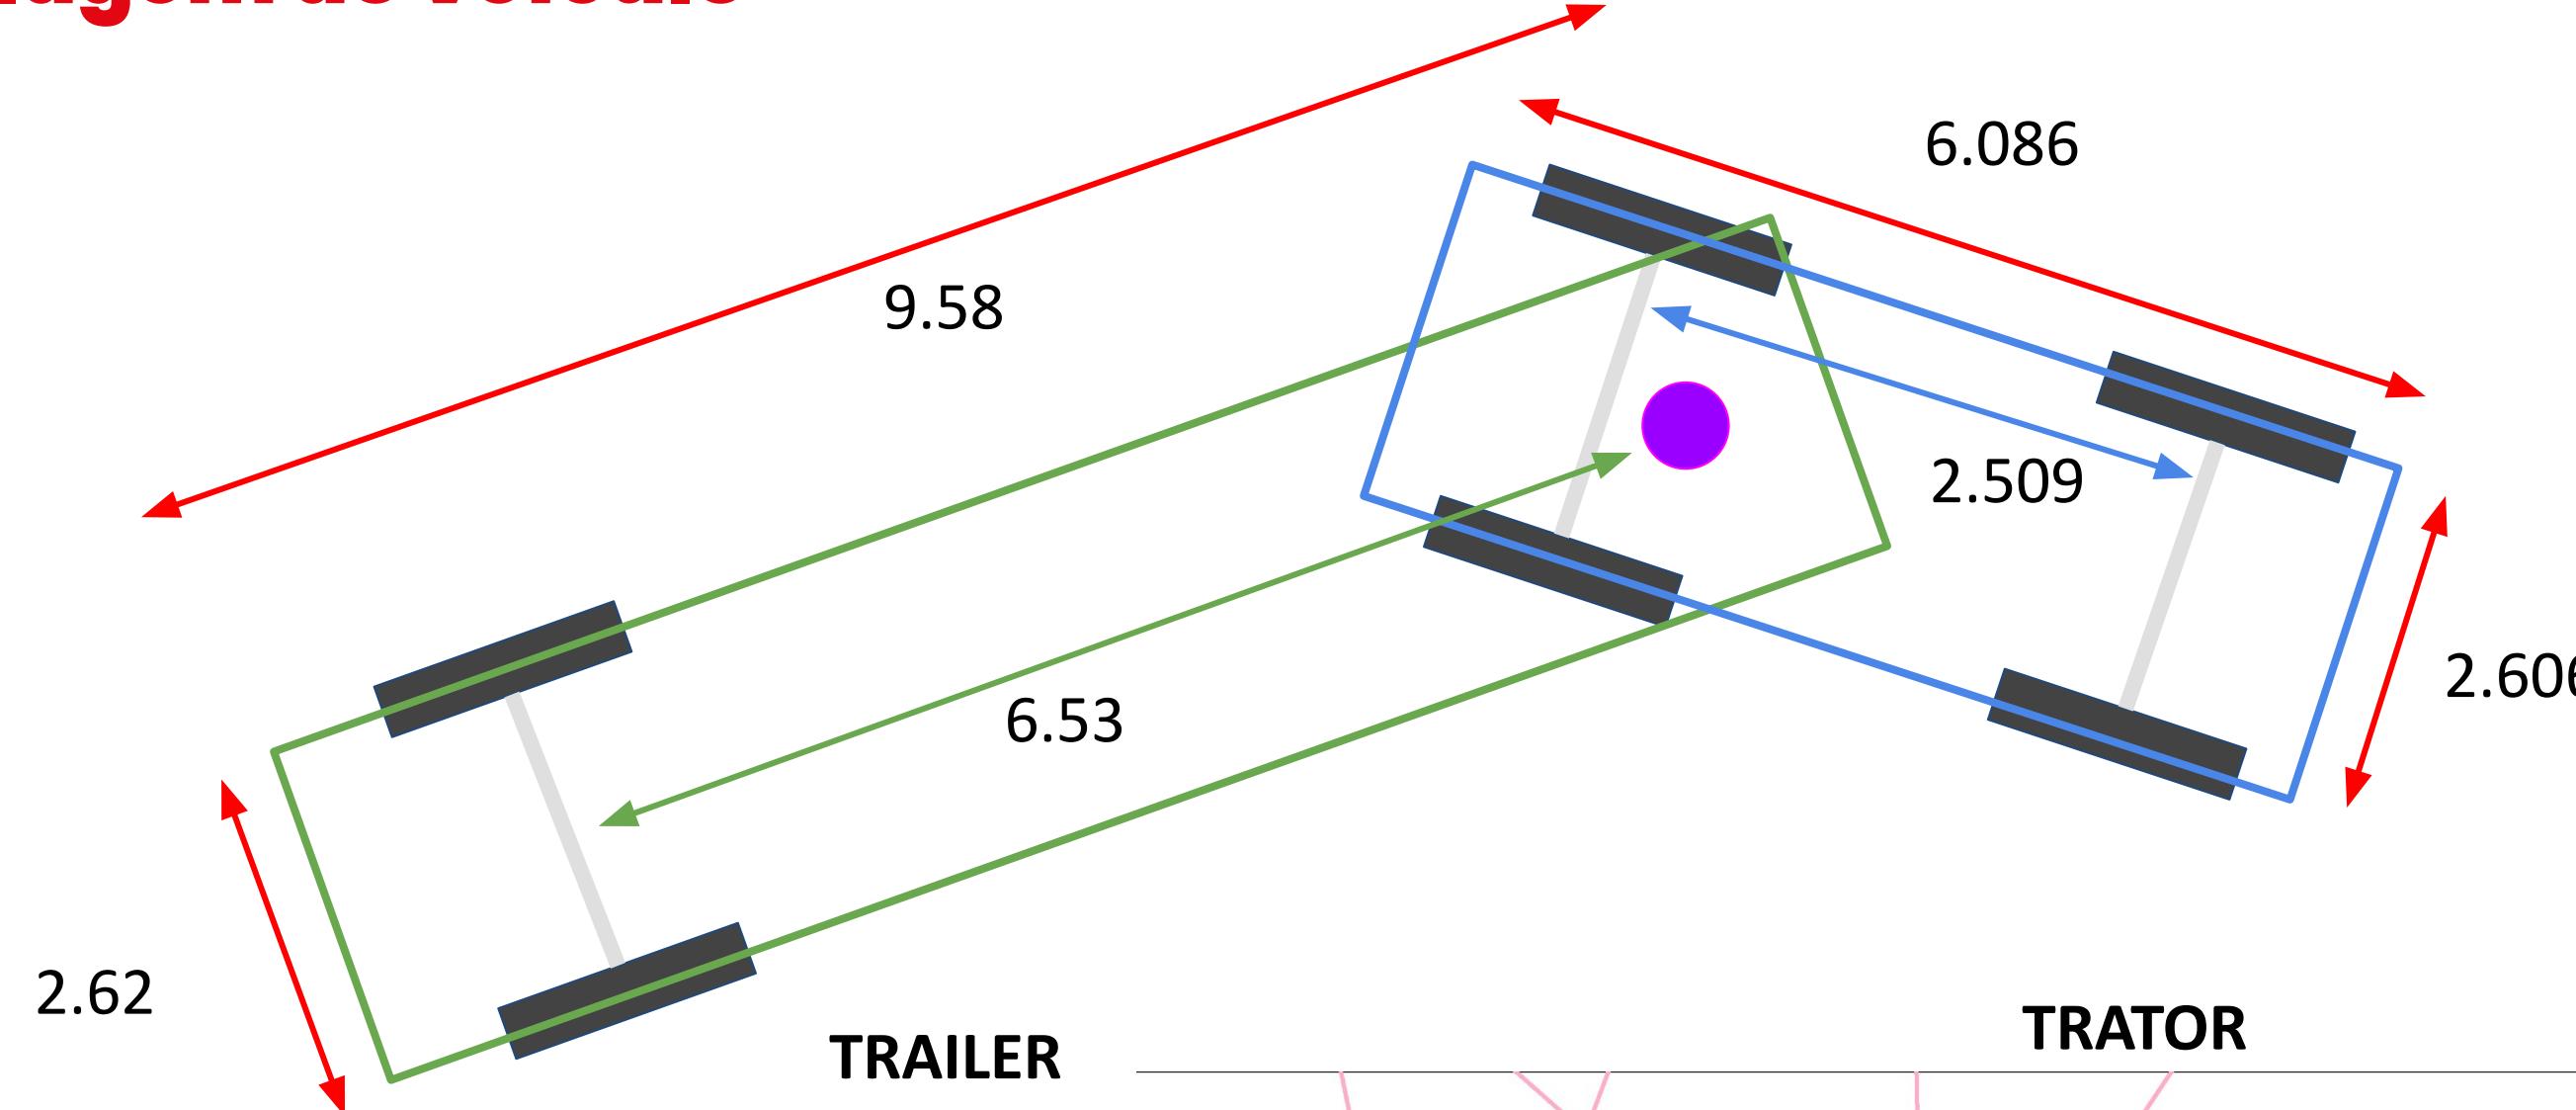
Jupyter Notebooks, Matplotlib, Pytest, Numpy

# O veículo

Representamos o veículo como um sistema cinemático de bicicleta articulado com três componentes principais:

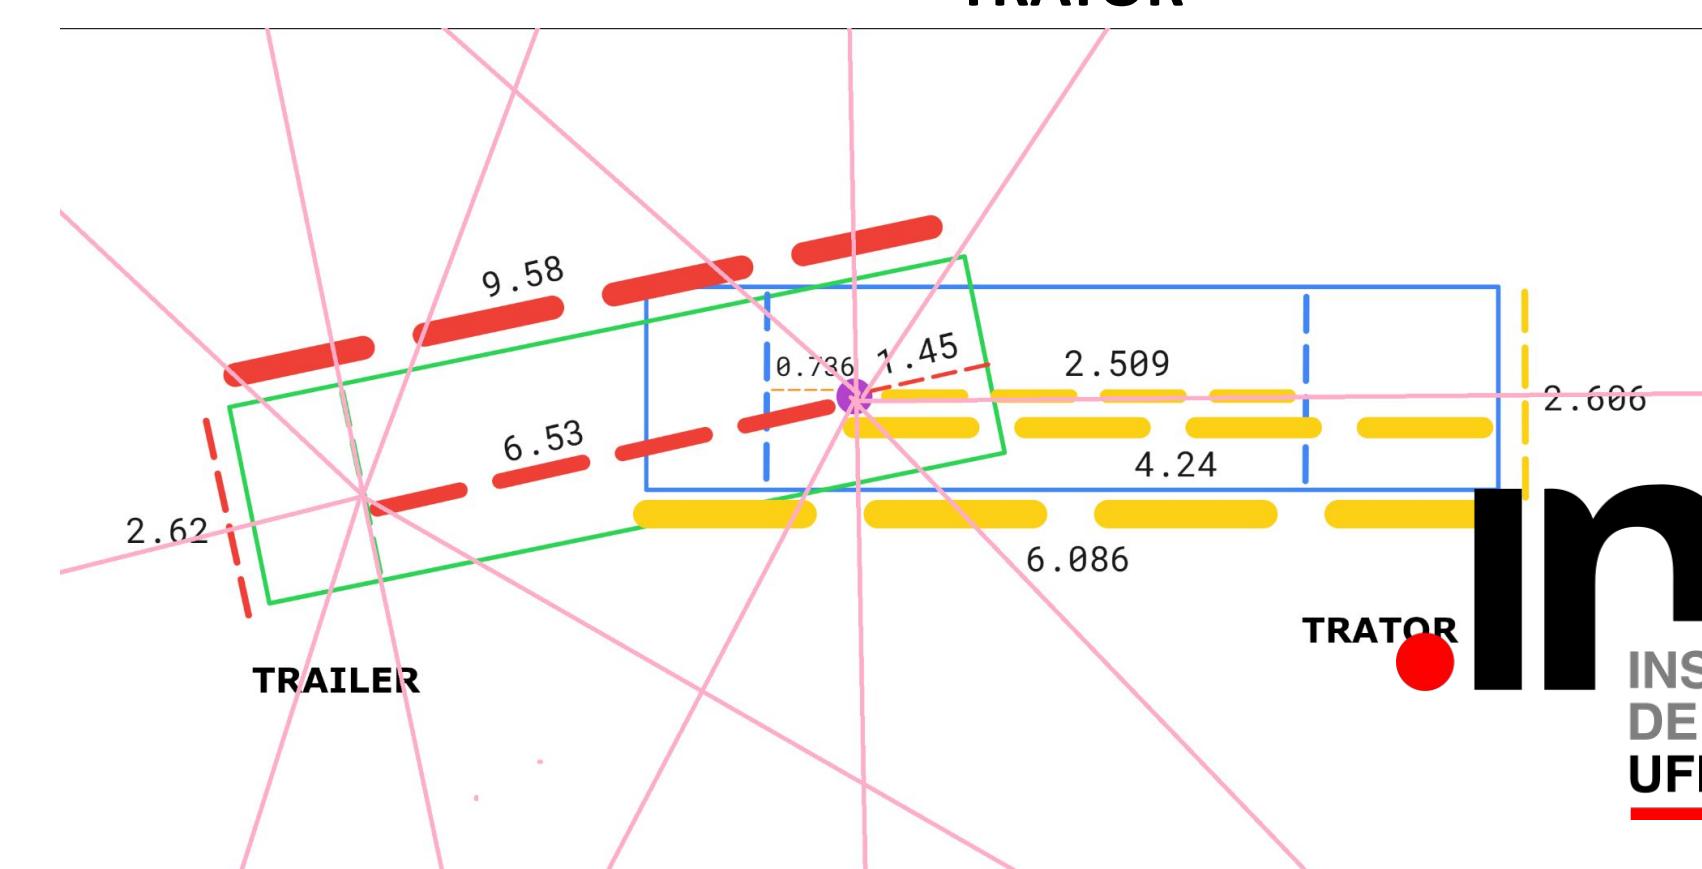
- Trator: posição  $(x, y)$ , orientação  $\theta$ , eixo traseiro como referência
- Trailer: acoplado ao trator pela quinta roda, orientação  $\theta_{\text{trailer}} = \theta - \beta$
- Articulação: ângulo  $\beta$  entre trator e trailer

## Modelagem do veículo



TRAILER

TRATOR



# Equações Cinemáticas – Modelo Bicicleta Cinético

O sistema é não-holonômico, o que significa que o veículo não pode se mover instantaneamente em qualquer direção (ele não pode andar de lado, por exemplo).

- Posição do trator

$$\dot{x} = v \cos(\theta_0) \quad \dot{y} = v \sin(\theta_0)$$

Onde:

$x, y$  Posição global do trator

$v$  Velocidade longitudinal do trator

$\delta$  Ângulo de esterçamento do trator

$L_1$  Distância entre-eixos do trator

$L_2$  Distância do ponto de engate até o eixo do reboque

- Orientação do trator

$$\dot{\theta}_0 = \frac{v}{L_1} \tan(\delta)$$

- Orientação do trailer

$$\dot{\theta}_1 = \frac{v \sin(\theta_0 - \theta_1) - d \cdot \dot{\theta}_0 \cos(\theta_0 - \theta_1)}{L_2}$$

# Ambiente físico

## Mapa

- Pares de fileiras de vagas apontando em direções opostas, com paredes entre elas

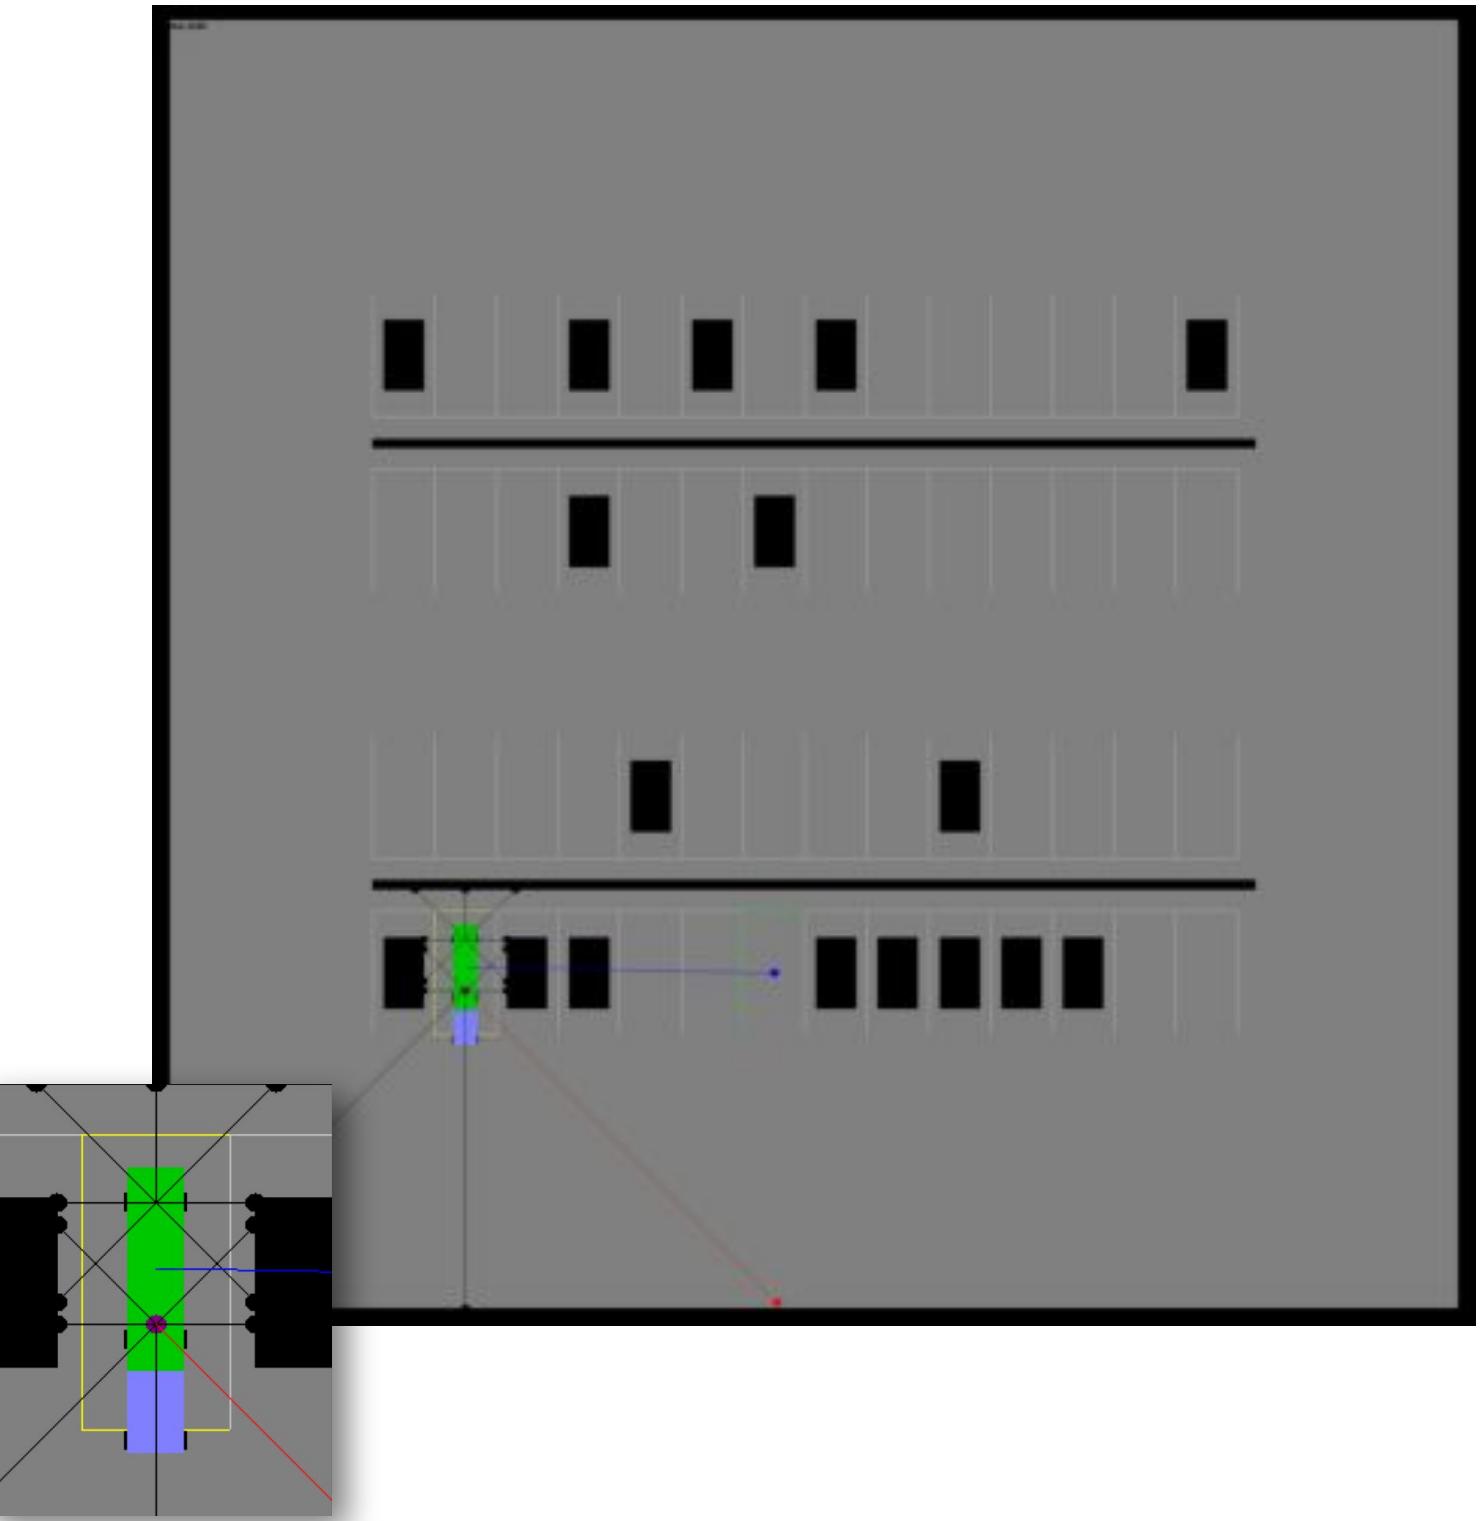
## Dimensões

- 150m x 150x -  $22500\text{m}^2$

## Randomização de domínio

- A cada geração, uma vaga aleatória é escolhida como ponto de partida e outra é escolhida como ponto de chegada (alvo)
- Quaisquer outras vagas tem uma chance de 25% de possuir um veículo estacionado sobre elas (obstáculo)

# Ambiente



# Ambiente Gymnasium

## Espaço de observação

$$\mathbf{s}_t = [v, \theta, \beta, \alpha, \mathbf{r}, \rho_g, \psi_{rel}, \Delta\theta_{tr}, \Delta\theta_{tl}]^T$$

Onde:

$v, \alpha$  : Velocidade longitudinal e ângulo de esterçamento atuais do trator;

$\theta, \beta$  : Orientação global do trator e ângulo de articulação do reboque;

$\mathbf{r} \in [0, 1]^{14}$  : Vetor de leituras de sensores LIDAR (\textit{raycasts}) para detecção de obstáculos;

$\rho_g$  : Índice de proximidade ao alvo, dado por  $(1 + \|\mathbf{p} - \mathbf{p}_{goal}\|_2)^{-1}$

$\psi_{rel}$  : Ângulo de azimute relativo (egocêntrico) em direção ao alvo;

$\Delta\theta_{tr}, \Delta\theta_{tl}$  : Erros de orientação do trator e do reboque, respectivamente, em relação à pose final desejada.

## **Função de Recompensa (esparsa)**

- +100 por completar o objetivo (estacionar na vaga de destino)
- +100 por alinhar o trailer na mesma orientação da vaga
- 100 por colisão com paredes ou outros obstáculos
- 100 por canivete (trailer acima do ângulo crítico)
- 20 distribuídos ao longo do episódio como penalidade por tempo
- 0.1 por velocidade zero a cada passo (penalidade por ficar parado)
- 0.02 por mudança brusca de esterçamento (smoothness penalty)

## **Fator da heurística**

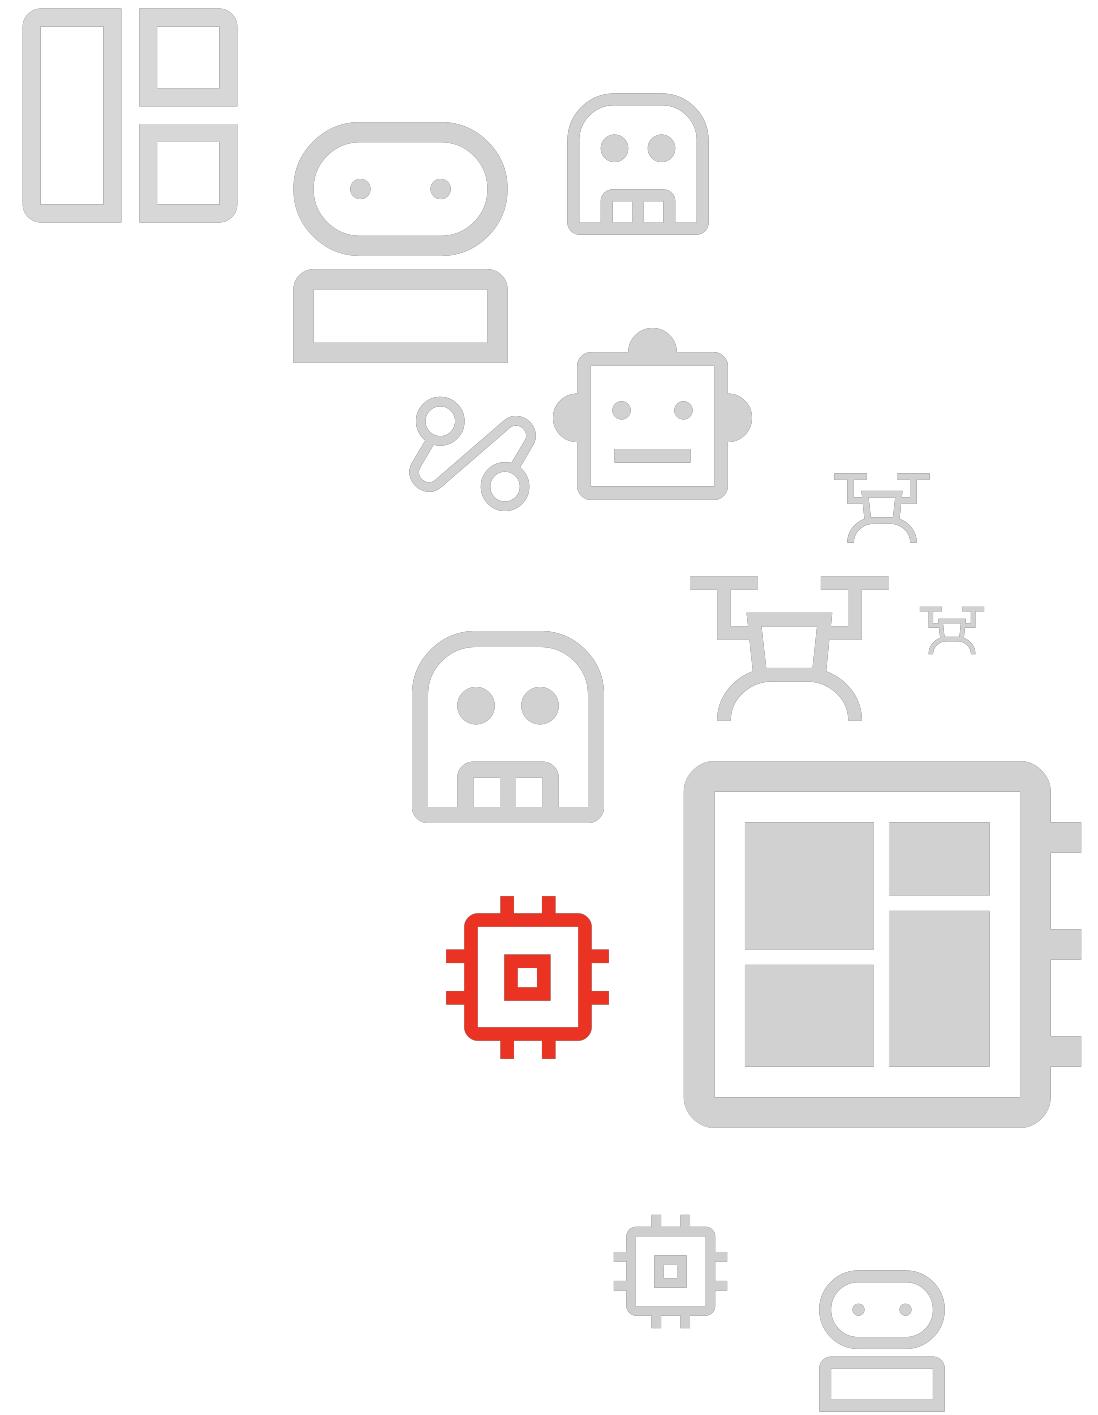
- +1.0 por progresso em direção ao objetivo (determinado pela heurística)

# Algoritmo

# Soft actor-critic

Variação do método Actor-Critic que busca maximizar a combinação de recompensa esperada e entropia da política.

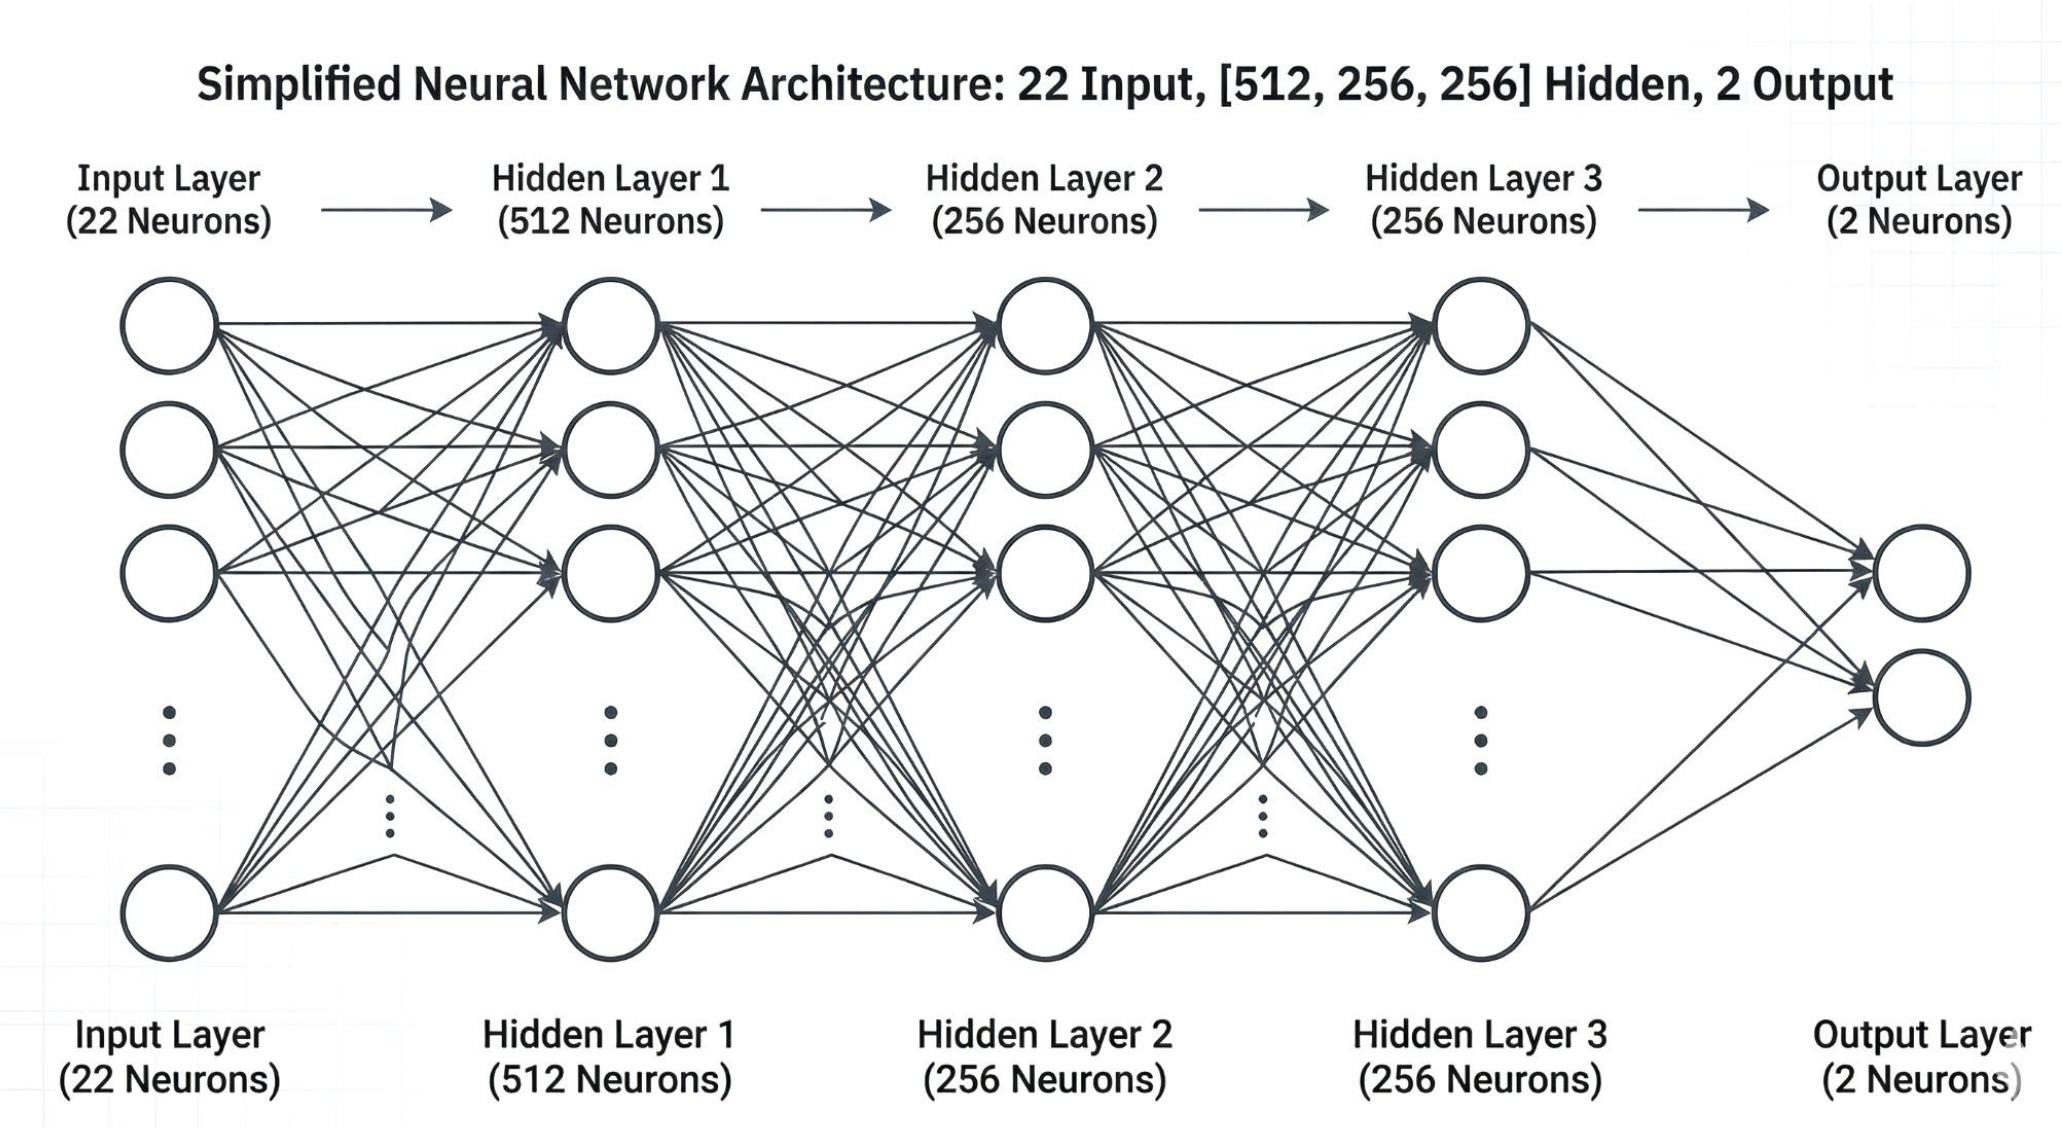
- Algoritmo de entropia máxima
- Espaço de ação contínuo
- Off-policy
- Model-free
- Estado-da-arte para tarefas de robótica com controle contínuo



# Configuração Paramétrica

## Arquitetura de rede neural

Definimos a mesma arquitetura de rede para o ator e o crítico, consistindo em uma rede de três camadas ocultas de 512, 256 e 256 neurônios, respectivamente.



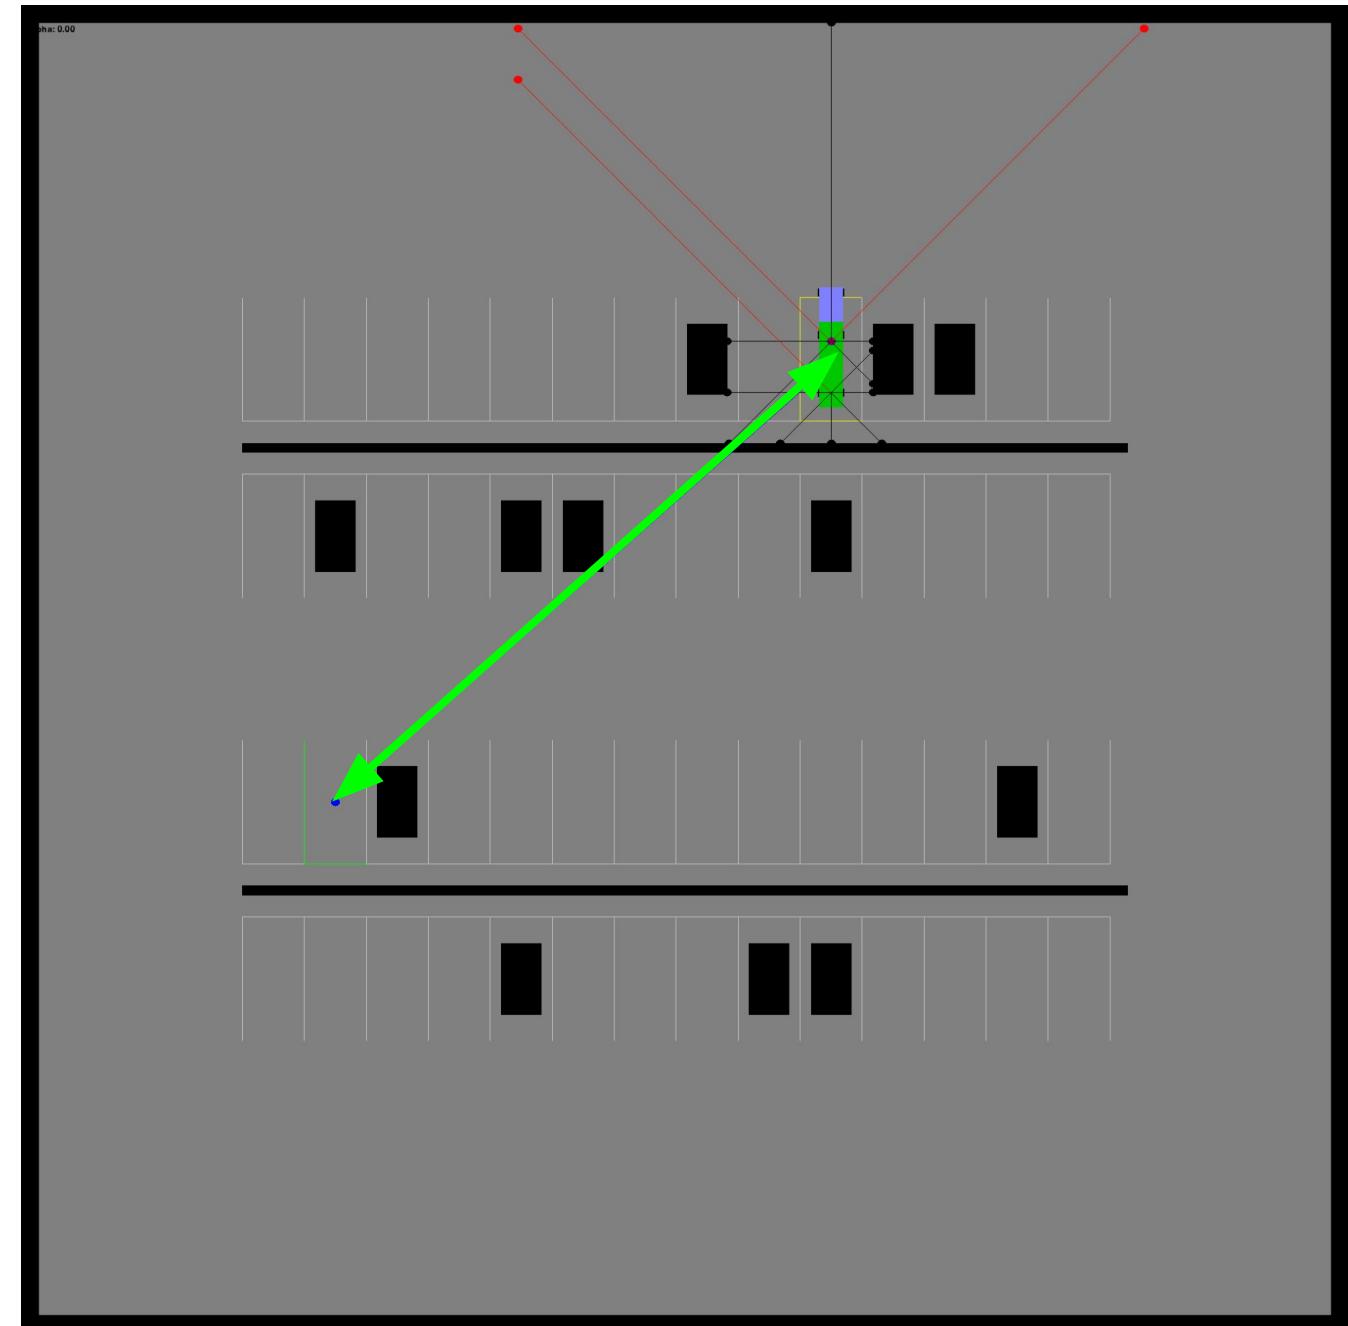
## Outros hiperparâmetros

- **Taxa de aprendizado:** 0.0003
- **Tamanho do buffer:** 1.000.000
- **Tamanho do minibatch:** 512
- **gamma:** 0.99
- **tau:** 0.005

# Heurísticas

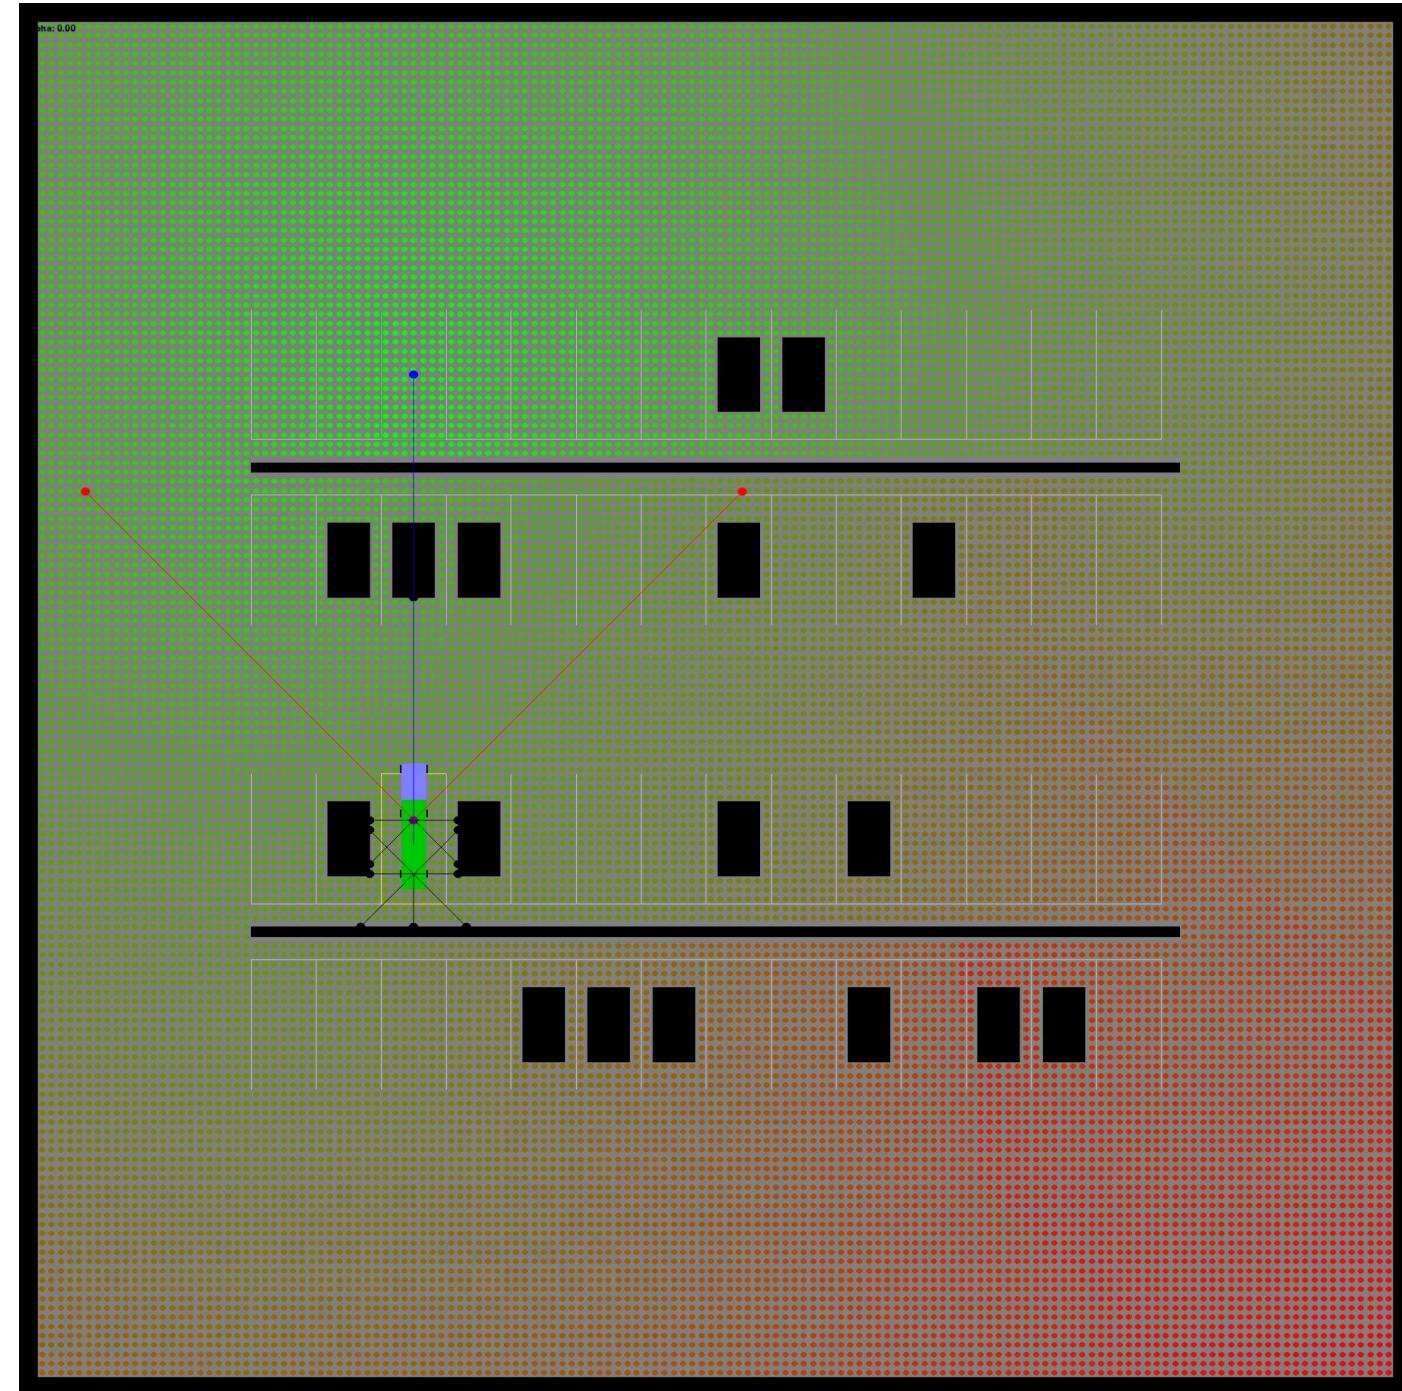
## Distância L2 (euclidiana)

Usamos a distância euclidiana do veículo até a vaga destino como sinal de recompensa. O agente é recompensado por reduzir essa distância a cada passo de simulação.

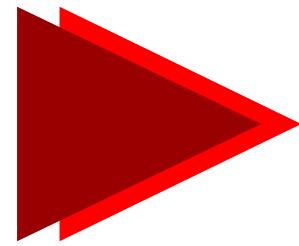


## BFS

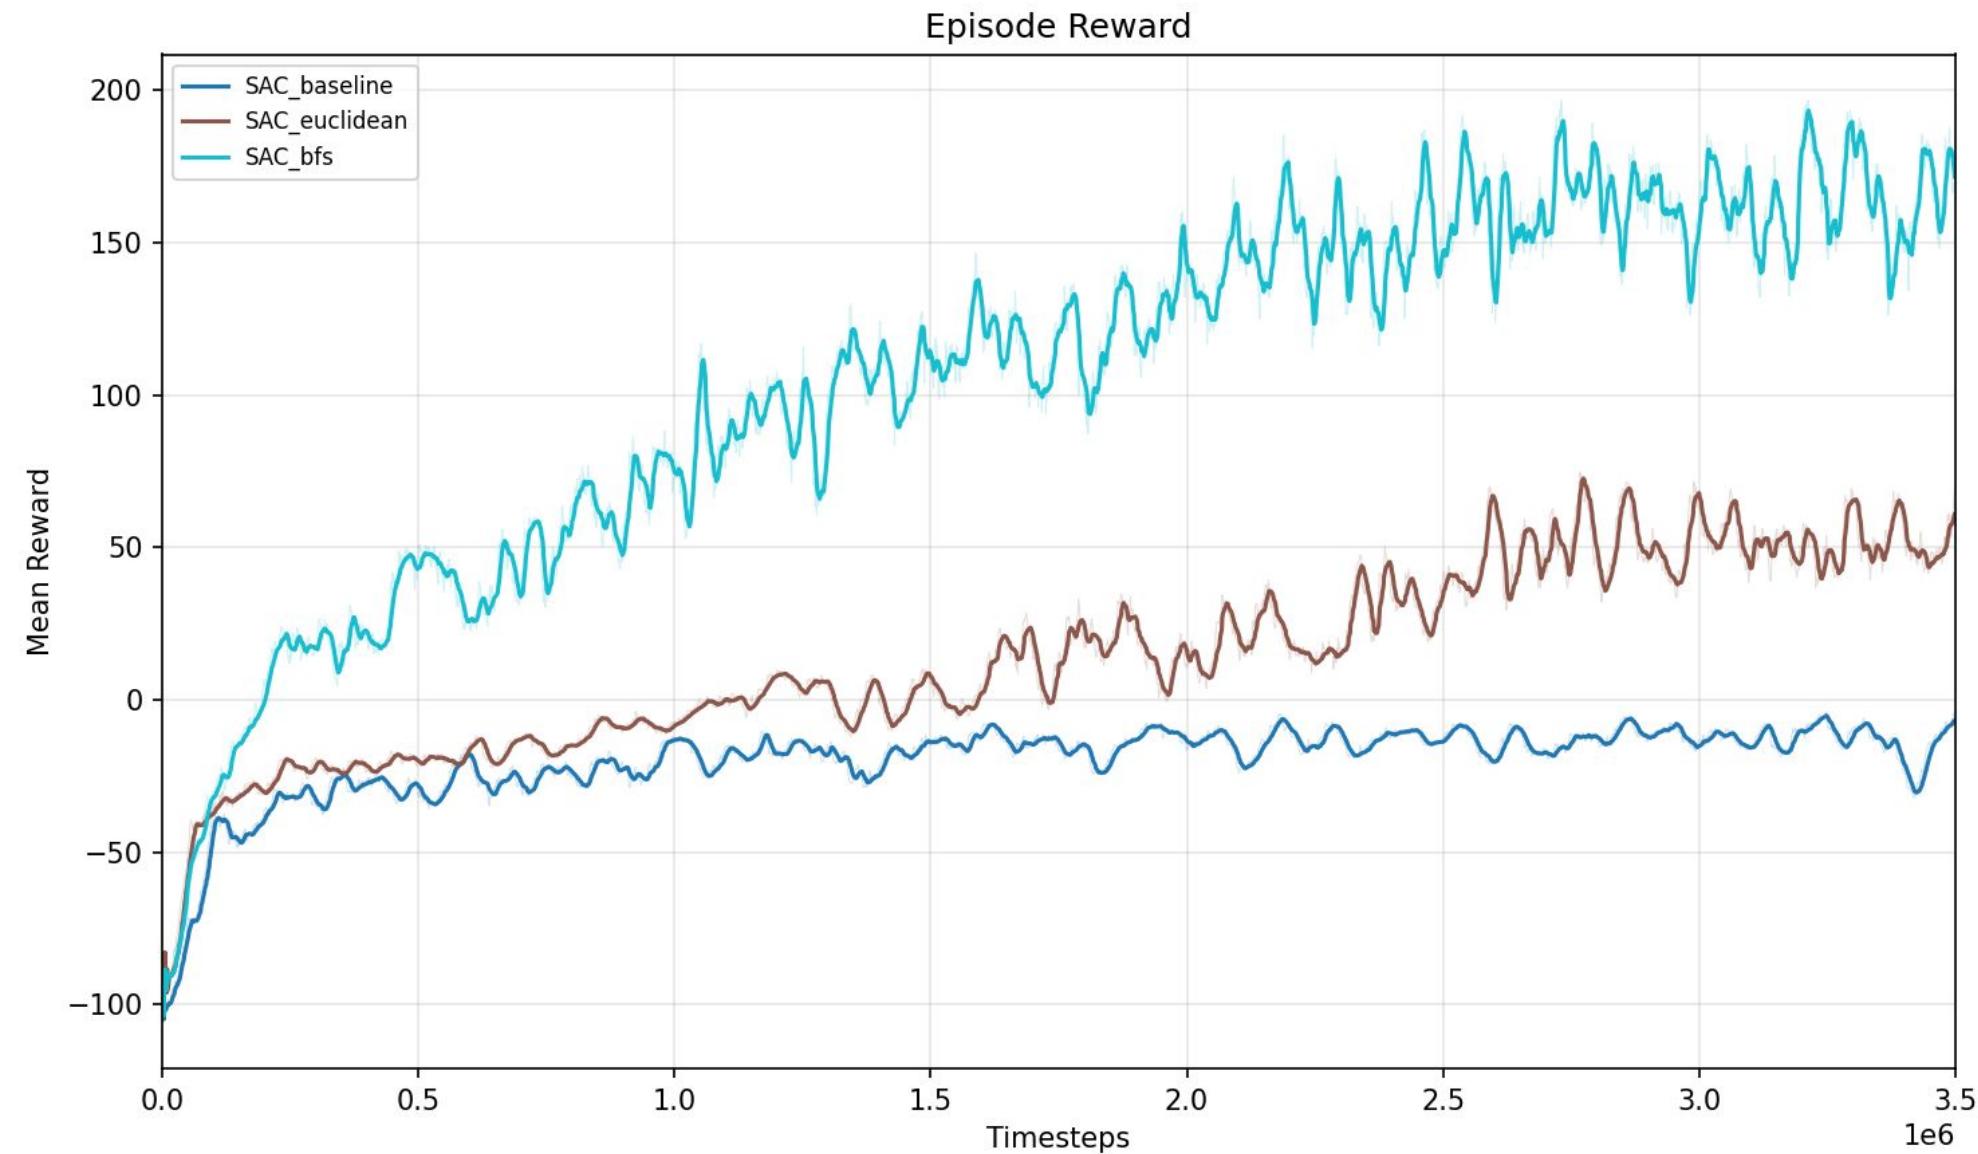
Primeiramente, discretizamos o mapa em pixels de  $1.0\text{m}^2$  e usamos o BFS (Breadth-first-search) a partir do alvo para computar um **mapa de distâncias** considerando todos os obstáculos do ambiente. Então, a recompensa do agente é calculada consultando-se esse mapa a cada passo e computando a diferença entre a distância anterior – também pelo BFS – e a atual.



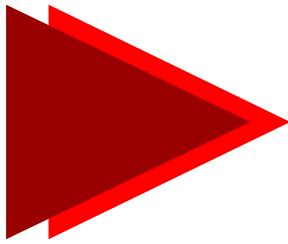
# Resultados



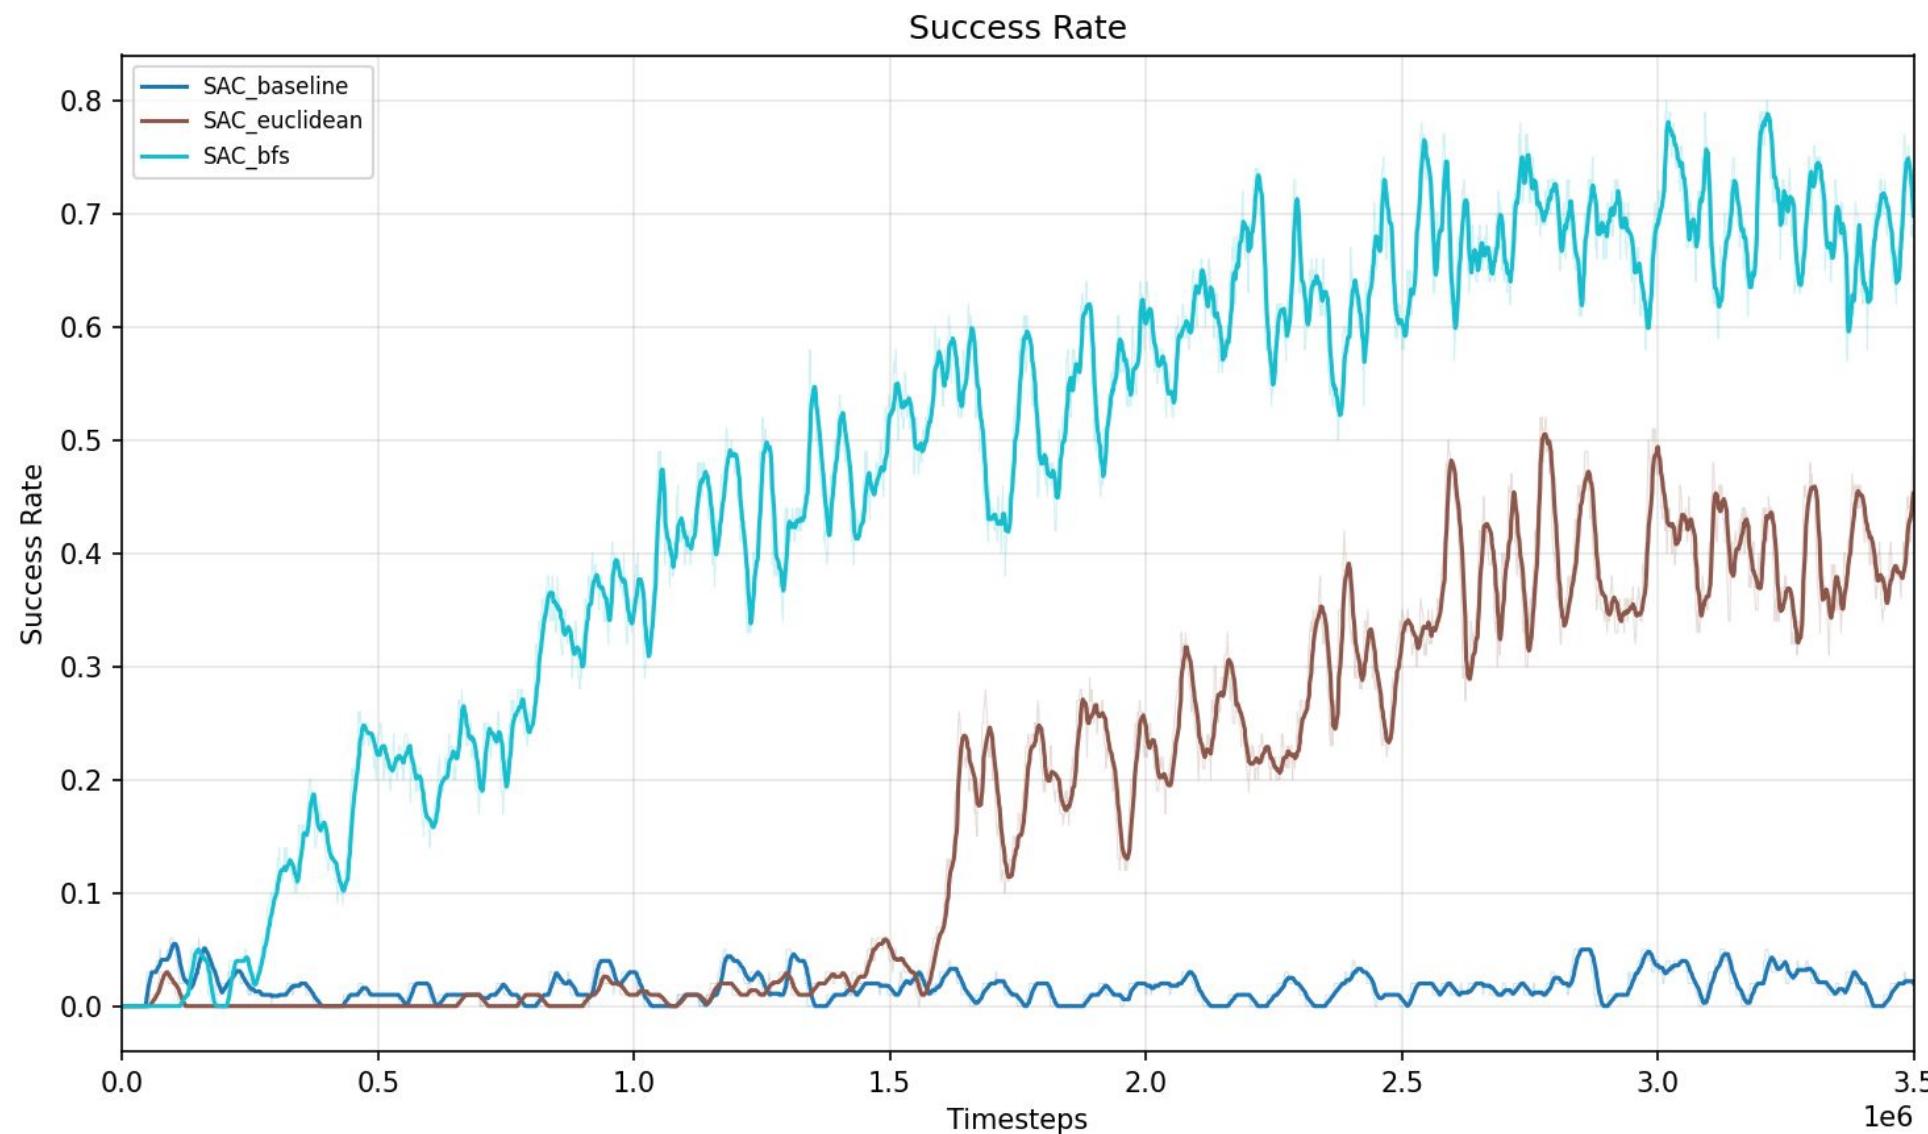
## Recompensa Média



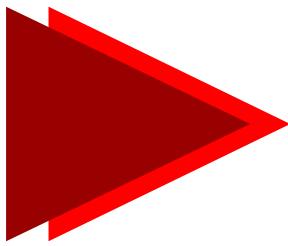
- Vantagem do BFS para o reward shaping fica evidente.
- O modelo que usa a heurística euclidiana tardou em encontrar o objetivo, e estabilizou a recompensa média em um limiar mais baixo.
- Baseline estabilizou dentro da faixa de recompensa negativa, indicando que ele aprendeu a ‘sobreviver’ (sem colisões), mas sem chegar ao objetivo



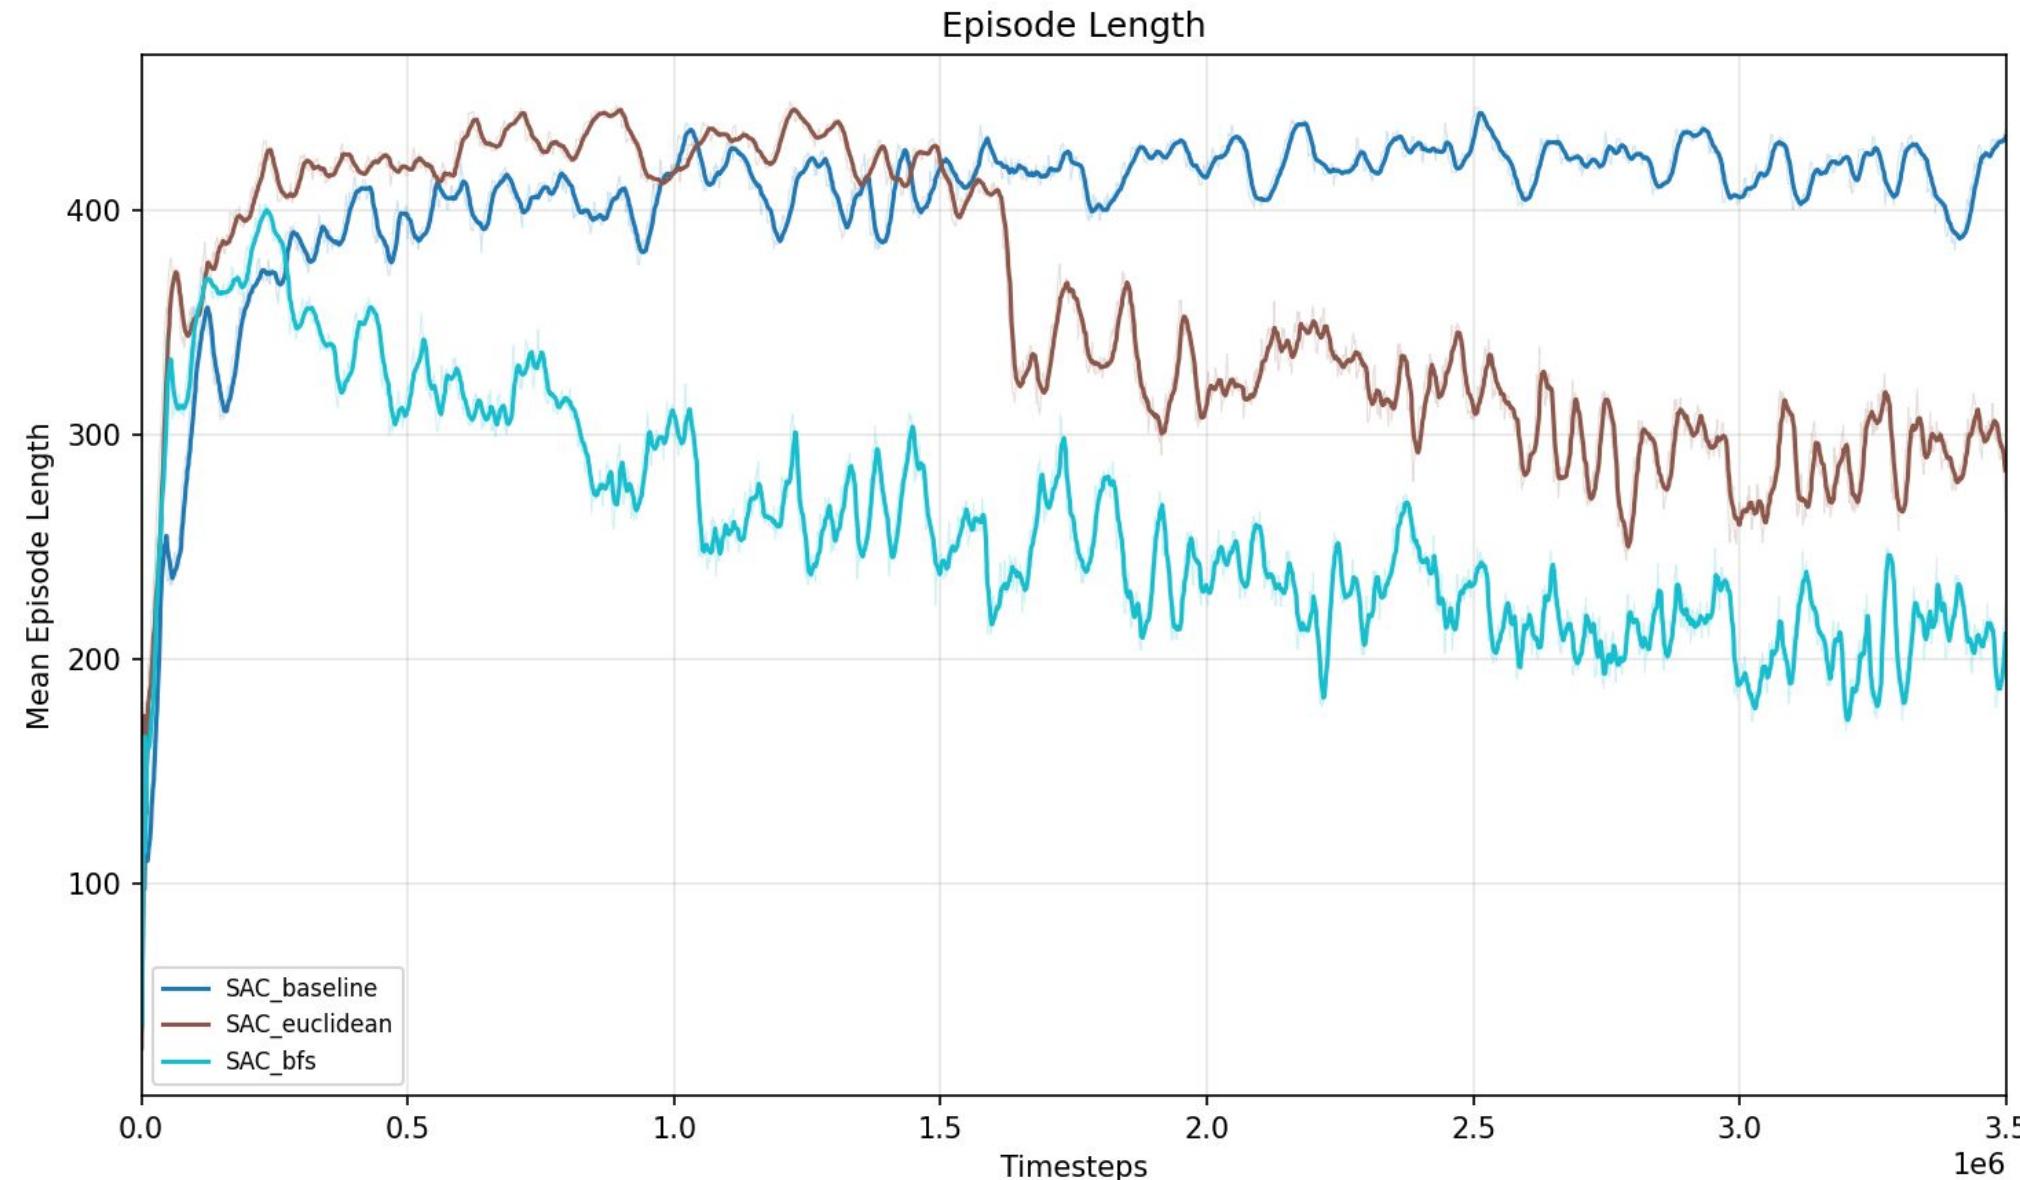
## Taxa de Sucesso



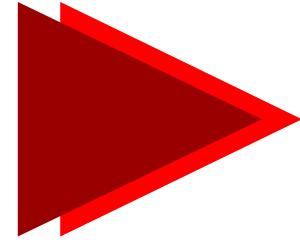
- Definimos taxa de sucesso como a frequência que o agente atinge o objetivo principal - estacionar na vaga.
- Novamente, BFS se sobressai com taxa de sucesso significativamente maior
- Heurística euclidiana estabiliza em um patamar menor - Obtém sucesso nos casos que não há obstáculo entre início e objetivo



## Duração de episódio



- a heurística mais 'inteligente' não apenas elevou a taxa de sucesso, mas também a velocidade de resolução do objetivo



# Conclusões

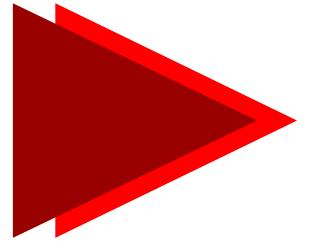
## Potencial de Reward shaping com HuRL

O HuRL apresenta um grande potencial de aumentar a eficiência do treinamento de agentes de RL em aplicações de planejamento de rotas. Em nosso caso, o aprendizado efetivo só foi possibilitado pelo uso de uma heurística.

- O reward shaping ajuda a superar a esparsidade recompensa do problema de estacionamento de veículos

## Dependência da heurística

O vantagem trazida pelo reward shaping depende fortemente da heurística escolhida. Quanto mais a heurística se conforma à dinâmica real do ambiente, maior o ganho de eficiência no treinamento do agente.



# Trabalhos futuros

## Avaliação com outras heurísticas

Analisar o desempenho de outras heurísticas, como Dijkstra, A\*, etc, incluindo heurísticas não-holonômicas.

## Uso de Coordenadas Privilegiadas

No decorrer do desenvolvimento, tomamos conhecimento das coordenadas privilegiadas, que podem trazer informações diretivas para o modelo que tem potência de levar a um aprendizado mais rápido, ficando como trabalho futuro.

## Exploração de outros algoritmos de RL

Analisar o desempenho de outros algoritmos de controle contínuo off-policy, como TD3, ou on-policy, como o PPO sob a ótica do HuRL, se faz necessário.

Diferentes algoritmos de RL podem se beneficiar do reward shaping em magnitudes distintas.

# Referências

## References

- [1] Ching-An Cheng, Andrey Kolobov, and Adith Swaminathan. Heuristic-guided reinforcement learning. *Advances in Neural Information Processing Systems*, 34:13550–13563, 2021.
- [2] Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, et al. Gymnasium: A standard interface for reinforcement learning environments. *arXiv preprint arXiv:2407.17032*, 2024.
- [3] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. Pmlr, 2018.
- [4] Chenyong Guan and Yu Jiang. A tractor-trailer parking control scheme using adaptive dynamic programming. *Complex & Intelligent Systems*, 8(3):1835–1845, 2022.
- [5] Mario Rosenfelder, Henrik Ebel, Jasmin Krauspenhaar, and Peter Eberhard. Model predictive control of non-holonomic systems: Beyond differential-drive vehicles. *Automatica*, 152:110972, 2023.

# Obrigado!